

# **UNIVERSIDAD TECNOLÓGICA DE LA MIXTECA**

## **RECONOCIMIENTO DE MELANOMA EN IMÁGENES DERMATOSCÓPICAS MEDIANTE MÉTODOS DE APRENDIZAJE PROFUNDO**

**PROTOCOLO DE TESIS**

**PRESENTA:**

**JUAN CARLOS GÓMEZ VILLANUEVA**

**DIRECTOR DE TESIS:**

**DR. RAÚL CRUZ BARBOSA**

**CODIRECTORA DE TESIS:**

**DRA. VERÓNICA RODRÍGUEZ LÓPEZ**

**HUAJUAPAN DE LEÓN OAXACA, NOVIEMBRE DE 2022**



# Indice general

<b>1. Introducción</b>	<b>3</b>
1.1. Planteamiento del problema . . . . .	4
1.2. Justificación . . . . .	6
1.3. Hipótesis . . . . .	7
1.4. Objetivos . . . . .	7
1.4.1. Objetivo general . . . . .	7
1.4.2. Objetivos específicos . . . . .	7
1.5. Metas . . . . .	7
1.6. Trabajos relacionados . . . . .	8
1.7. Metodología . . . . .	9
1.8. Índice preliminar . . . . .	10
1.9. Cronograma de actividades . . . . .	11
<b>2. Marco Teórico</b>	<b>13</b>
2.1. Detección del Cáncer de melanoma mediante imágenes dermatoscópicas . . .	13
2.1.1. Cáncer de Melanoma . . . . .	13
2.1.2. Uso de imágenes dermatoscópicas . . . . .	14
2.2. Preprocesamiento general de imágenes . . . . .	17
2.2.1. Métodos de preprocesamiento en imágenes dermatoscópicas . . . . .	17
2.3. Aprendizaje profundo . . . . .	19
2.3.1. Introducción . . . . .	19
2.3.2. Redes neuronales profundas . . . . .	20
Bibliografía . . . . .	21

## Resumen

En México, la tasa de mortalidad por melanoma ha incrementado 78 % en los últimos 19 años, siendo las personas mayores a 60 años los más afectados. Además, a nivel mundial es considerado como el tipo de cáncer de piel más agresivo y mortal que existe.

La técnica llamada dermatoscopia es ampliamente utilizada por especialistas para reconocer lesiones cutáneas sospechosas de ser melanoma, ya que permite una mayor visualización de estas lesiones. Sin embargo, la evaluación visual de una gran cantidad de imágenes dermatoscópicas suele producir fatiga y pérdida de agudeza visual al especialista. Además, esta técnica puede ser subjetiva y carecer de reproducibilidad, aunado al costo para acceder a un especialista.

El presente trabajo tiene como propósito desarrollar una aplicación web en idioma español para reconocimiento de melanoma en imágenes dermatoscópicas, que integre diferentes modelos híbridos de aprendizaje profundo para lograr un alto rendimiento de clasificación (mayor a 90 % en medidas de exactitud y sensibilidad).

# Capítulo 1

## Introducción

El melanoma es considerado a nivel mundial como el tipo de cáncer de piel más agresivo y mortal que existe. Con frecuencia se origina debido a alteraciones en el desarrollo de células de tipo melanocitos, encargadas de producir melanina (el pigmento marrón de la piel) (ACS, 2022b) estas alteraciones reflejan características particulares (o anormales) que son detectables visualmente en imágenes dermatoscópicas. Por este motivo existe una relación directa entre los patrones que presentan las lesiones y su naturaleza patológica (Goyal et al., 2020).

En México la tasa de mortalidad por melanoma se ha incrementado considerablemente en los últimos 19 años, independientemente del sexo y la edad de la población, siendo las personas mayores a 60 años los más afectados (Hernández-Domínguez et al., 2019). Además, se estima que en el año 2020 fallecieron 57,043 personas a nivel mundial a causa de melanoma (ASCO, 2019).

Debido a su alto nivel de mortalidad, resulta de suma importancia el diagnóstico temprano y certero del melanoma, así como el tratamiento oportuno para mejorar la supervivencia de esta enfermedad. Una adecuada valoración clínica del paciente con sospecha de melanoma incluye una minuciosa anamnesis por aparatos y sistemas. Primero, la exploración física consta de un examen cutáneo de toda la superficie corporal y palpación de todos los territorios ganglionares accesibles (POCV, 2010). Si el médico sospecha de que alguna lesión cutánea pueda ser melanoma, se extrae una muestra del área de interés y se envía a un laboratorio para examinarla en el microscopio. Esto se conoce como biopsia de piel. Sin embargo, a pesar de ser un diagnóstico altamente confiable, este método es invasivo y bastante costoso (ACS, 2022a).

Otra alternativa de exploración es la dermatoscopia (también llamada microscopía de epiluminiscencia o microscopía de superficie) la cual es una técnica no invasiva que permite observar con mayor claridad las lesiones de la piel en comparación con el ojo sin ayuda de

un dermatoscopio (Conforti et al., 2019). Aquí se utiliza el método de “análisis de patrones” con el que se obtienen mejores resultados, pues permite una inspección visual más completa de las lesiones pigmentadas pero requiere mayor entrenamiento del especialista (Zaballos et al., 2004). Otra técnica o método utilizado es la regla ABCD, la cual permite a los especialistas menos experimentados alcanzar una alta sensibilidad en el diagnóstico (Tsao et al., 2004).

Debido principalmente al aumento de tecnologías computacionales y a la disponibilidad de bases de datos de acceso libre, en la última década, se ha impulsado el desarrollo de métodos computacionales para la asistencia de diagnósticos médicos. En la literatura existen trabajos que tratan el reconocimiento de melanoma en imágenes dermatoscópicas mediante aprendizaje computacional (Wahba, 2018; Melbin y Raj, 2021; Khan et al., 2019). Sin embargo, una desventaja importante de estos es la enorme pérdida de rendimiento cuando no se captura la lesión completa a analizar dentro de la imagen dermatoscópica. Esto es conocido como factor de oclusión.

Por otro lado, en la actualidad existen modelos de aprendizaje profundo como las redes neuronales convolucionales (CNN, por sus siglas en inglés), que de forma general han mostrado mejores rendimientos en comparación con los métodos tradicionales, y que además son capaces de superar el problema del factor de oclusión. Lo anterior es posible debido a que las CNN’s pueden aprender a reconocer patrones en las imágenes mientras extraen características abstractas en diferentes escalas de forma automática (Vasilev et al., 2019). Además, también hay trabajos que han combinado métodos tradicionales con métodos de aprendizaje profundo, un ejemplo es (Anjum et al., 2020) quienes proponen clasificar con máquinas de vectores de soporte (SVM, por sus siglas en inglés) los vectores de características extraídos por una arquitectura ResNet-18.

El presente trabajo de tesis tiene como objetivo implementar una aplicación web que permita detectar el melanoma en imágenes dermatoscópicas mediante métodos de aprendizaje profundo. Para alcanzar el objetivo, la metodología propuesta se divide en tres etapas: en la primera se realiza la adquisición y el preprocesamiento de las imágenes dermatoscópicas; en la segunda etapa se realiza la implementación y el entrenamiento de los algoritmos de reconocimiento de melanoma mediante modelos híbridos de aprendizaje profundo. Finalmente, en la última etapa se desarrolla una aplicación web para integrar y mostrar el uso práctico del algoritmo de reconocimiento de melanoma.

## 1.1. Planteamiento del problema

De acuerdo a (Palacios-Martínez y Díaz-Alonso, 2017) la dermatoscopia es una técnica ampliamente utilizada para realizar el diagnóstico visual de las lesiones de la piel. Esta es

una técnica no invasiva desarrollada en los últimos años para identificar estructuras cutáneas profundas, denominadas estructuras dermatoscópicas, no visibles a simple vista y que sugieren malignidad.

El rendimiento del diagnóstico dermatoscópico depende de la regla o método elegido para analizar las imágenes dermatoscópicas, así como de la experiencia del especialista. En este sentido, la evaluación de una gran cantidad de imágenes mediante la inspección visual dermatoscópica suele ser una tarea monótona, generando inconvenientes como la fatiga y la pérdida de agudeza visual (Zaballos et al., 2004).

Por otro lado, las características presentes en las imágenes dermatoscópicas pueden ser aprovechadas por las técnicas de visión y aprendizaje computacional para ayudar en el reconocimiento de esta enfermedad. En la literatura consultada se pueden encontrar ejemplos del uso de imágenes dermatoscópicas para el reconocimiento de melanoma, abordado este tema desde diferentes enfoques del aprendizaje computacional tradicional (Wahba, 2018; Melbin y Raj, 2021; Khan et al., 2019). Sin embargo, el rendimiento de estos modelos se ve afectado cuando la lesión de interés no se captura completa dentro de la imagen, esto se conoce como factor de oclusión.

Además, los métodos de aprendizaje profundo han tomado gran relevancia en problemas de clasificación y segmentación de imágenes dermatoscópicas, ya que de manera general permiten obtener mejores resultados en comparación con las técnicas de aprendizaje computacional tradicionales (Naeem et al., 2020). Es decir, estos algoritmos enfrentan de mejor manera el problema del factor de oclusión visual, debido a que son capaces de aprender de forma automática las características que componen al objeto de interés (Vasilev et al., 2019). Por ejemplo, en (Sarkar et al., 2019) desarrollaron un modelo de clasificación para reconocer melanoma y nevus melanocítico a partir de imágenes dermatoscópicas utilizando redes residuales y redes de convolución separables en profundidad. Con el mismo objetivo de clasificación binaria, en (Amin et al., 2020) desarrollaron un algoritmo basado también en CNN's.

También, en la literatura consultada se pueden encontrar ejemplos de trabajos que desarrollan sistemas web que integran métodos de aprendizaje profundo, supervisados y no supervisados para la detección de melanoma (Mazoure et al., 2022). Incluso, existen algunos sistemas desarrollados en idioma español (Quero-Caiza y Altuve, 2022; López-Salmerón, 2021). Sin embargo, los sistemas previamente mencionados no combinan la integración de una aplicación web en idioma español utilizando aprendizaje profundo para el reconocimiento de melanoma. Es decir, son sistemas desarrollados en inglés o no utilizan aprendizaje profundo.

Por lo anterior, en este proyecto de tesis se pretende implementar una aplicación web en idioma español que integre algoritmos basados en aprendizaje profundo para el reconoci-

miento de melanoma.

## 1.2. Justificación

Debido a que existe una relación directa entre los patrones que presentan las lesiones y su naturaleza patológica, se ha desarrollado una técnica llamada dermatoscopia para identificar visualmente estructuras cutáneas profundas, no visibles a simple vista y que sugieren malignidad. Por lo anterior, realizar una inspección dermatoscópica es vital para proporcionar información útil a los especialistas sobre la malignidad de las lesiones.

Desafortunadamente, el rendimiento del diagnóstico dermatoscópico visual depende de la experiencia, así como del método elegido para analizar las imágenes dermatoscópicas. Además, esta técnica puede llegar a ser una tarea monótona al evaluar una gran cantidad de imágenes, generando inconvenientes como son la fatiga y la pérdida de agudeza visual.

Por otro lado, las técnicas de procesamiento digital de imágenes y aprendizaje profundo permiten ayudar en el reconocimiento de melanoma en una gran cantidad de imágenes dermatoscópicas. Estas disciplinas han mostrado gran capacidad para tratar los problemas de identificación y reconocimiento de melanoma. Entonces, con ayuda de estas se puede minimizar el esfuerzo de los especialistas para reconocer patrones difíciles de identificar a simple vista.

Una revisión por nuestra parte de sistemas y aplicaciones para el reconocimiento de melanoma arroja que en el mercado existen equipos capaces de automatizar el diagnóstico dermatoscópico, lamentablemente los altos costos de estos equipos los hacen poco accesibles para hospitales e instituciones. También existen aplicaciones web que realizan el reconocimiento de melanoma. Un ejemplo es SkinVision®<sup>1</sup>, que localiza automáticamente las lesiones cutáneas y realiza el reconocimiento de melanoma mediante métodos de aprendizaje profundo. Otros como SkinScan®<sup>2</sup> de Teleskin localiza automáticamente las lesiones cutáneas y realiza el reconocimiento de melanoma mediante la regla dermatoscópica ABCD. Desafortunadamente, esas aplicaciones web son licenciadas, lo cual significa que los modelos de aprendizaje profundo que utilizan no los comparten con la comunidad científica, y para utilizarlos se requiere pagar una suscripción, lo cual limita su acceso. Además, estos no se encuentran disponibles en idioma español.

Aun cuando existen trabajos realizados internacionalmente en los que abordan las tareas de reconocimiento de melanoma mediante métodos de aprendizaje profundo, en México el trabajo de investigación y desarrollo tecnológico es mínimo. Por las razones anteriores, en este trabajo de tesis se propone desarrollar una aplicación web en idioma español para reconocimiento de melanoma, con la finalidad de ayudar a realizar la detección usando



imágenes dermatoscópicas. Esto es, se pretende generar una aplicación web que presente un alto rendimiento para la asistencia en el diagnóstico de dicha enfermedad.

## 1.3. Hipótesis

Es posible desarrollar una aplicación web en idioma español para reconocimiento de melanoma en imágenes dermatoscópicas, que integre diferentes modelos híbridos de aprendizaje profundo para lograr un alto rendimiento de clasificación (mayor a 90 % en medidas de exactitud y sensibilidad).

## 1.4. Objetivos

### 1.4.1. Objetivo general

Implementar una aplicación web en idioma español para realizar clasificación de melanoma mediante métodos de aprendizaje profundo usando imágenes dermatoscópicas.

### 1.4.2. Objetivos específicos

1. Revisar el estado del arte sobre métodos de clasificación de melanoma mediante algoritmos de aprendizaje profundo. Además, revisar métodos de preprocesamiento de imágenes dermatoscópicas.
2. Seleccionar un conjunto de datos público de imágenes dermatoscópicas utilizado para la clasificación de melanoma.
3. Implementar un algoritmo de aprendizaje profundo para la clasificación de melanoma.
4. Evaluar los resultados obtenidos del clasificador de melanoma.
5. Desarrollar una aplicación web que reciba una imagen dermatoscópica y haga uso de los algoritmos implementados para detectar melanoma.

## 1.5. Metas

1. Elaboración de un reporte sobre los métodos de preprocesamiento de imágenes dermatoscópicas.
2. Elaboración de un reporte sobre los métodos de reconocimiento de melanoma utilizando aprendizaje profundo.

3. Implementación de un módulo en Python para la clasificación de melanoma en imágenes dermatoscópicas usando un algoritmo de aprendizaje profundo.
4. Integración del módulo desarrollado en el punto anterior en una aplicación web (en lenguaje Python) que sea capaz de reconocer el cáncer de melanoma en una imagen dermatoscópica.
5. Elaboración de un reporte comparativo del desempeño del modelo de clasificación de melanoma contra otros modelos relacionados de la literatura.
6. Elaboración del documento de tesis.

## 1.6. Trabajos relacionados

Dada la problemática de realizar un reconocimiento de melanoma de manera eficiente, en la literatura se pueden encontrar distintas investigaciones para obtener altos rendimientos en esta tarea. A continuación, se mencionan algunos trabajos relacionados con el presente proyecto de tesis.

En (Kasmi y Mokrani, 2016) inicialmente, proponen un filtro Gabor y contornos activos geodésicos para mejorar la imagen y eliminar el vello. Luego se utiliza la regla ABCD para extraer las características y finalmente utilizan una combinación de métodos de aprendizaje computacional para clasificar las lesiones.

En (Wahba, 2018) propusieron un sistema de clasificación de lesiones cutáneas basado en el método de diferencia de niveles de gris. Aquí, discriminan entre cuatro lesiones extrayendo características mediante la regla ABCD y la media de diferencia de nivel acumulada. Finalmente, estas características se clasificaron utilizando una SVM. Del mismo modo (Majumder y Ullah, 2019) propusieron tres características que se usaron en la clasificación del melanoma según la regla ABCD.

Por otro lado, recientemente, se han concentrado los esfuerzos en el desarrollo de métodos de aprendizaje profundo, por ejemplo, en (Yuan et al., 2017) propusieron un sistema de segmentación de lesiones cutáneas aprovechando la potencia de CNN's. En lugar de utilizar la función de pérdida tradicional, utilizaron la distancia de Jaccard como función de pérdida. En este sentido (Sultana et al., 2018) propusieron un sistema de detección de lesiones cutáneas utilizando un aprendizaje residual profundo con un marco regularizado.

En (Xie et al., 2016), la lesión se extrajo utilizando una red neuronal. Luego, se eliminaron las características descriptivas del borde, la textura y el color. Finalmente, se utilizó un método de ensamble que combinaba redes neuronales difusas con redes neuronales de

retropropagación (BP) para clasificar las lesiones en función de las características extraídas.

Siguiendo con el desarrollo de arquitecturas convolucionales en (Sarkar et al., 2019) propusieron una red convolucional profunda residual separable en profundidad para clasificar el cáncer de piel. El filtro de medios no locales fue reemplazado por la ecualización de histograma adaptable limitada por contraste (CLAHE) sobre el algoritmo de transformada de ondículas discretas (DWT, por sus siglas en inglés).

También en (Hosny et al., 2020) propusieron un nuevo sistema de clasificación CNN profunda para las lesiones cutáneas. Los autores realizaron tres experimentos diferentes con tres conjuntos de datos. Compararon la precisión entre el uso de clasificadores de aprendizaje computacional tradicionales y la tecnología emergente con CNN. Descubrieron que el clasificador de aprendizaje automático convencional conducía a una tasa de clasificación más baja.

Utilizando el enfoque de redes generativas antagónicas, en (Gong et al., 2020) propusieron un sistema de clasificación de imágenes dermatoscópicas de la piel. Los autores mejoraron las imágenes de la piel usando StyleGAN, mientras que la imagen mejorada se clasificó usando 43 CNN's. Las CNN's se dividieron en tres grupos con diferentes métodos de fusión. Finalmente, la decisión de clasificación se generó mediante la técnica de voto mayoritario.

## 1.7. Metodología

Para abordar el tema de clasificación de melanoma usando imágenes dermatoscópicas, se realizará un estudio sobre las características que presentan dichas imágenes pertenecientes a pacientes con esta enfermedad, así como de los diferentes métodos de clasificación que han sido utilizados dentro del ámbito computacional. Lo anterior, poniendo especial atención en el uso de métodos de aprendizaje profundo.

La figura 1.1 muestra las etapas que conforman la metodología del presente proyecto de tesis.

- Etapa 1. En esta etapa se realiza la adquisición y preprocesamiento de la información para poder llevar a cabo el reconocimiento de melanoma.
  1. Adquisición de datos. Las imágenes dermatoscópicas a utilizar en el presente trabajo serán tomadas de conjuntos de imágenes públicos.
  2. Preprocesamiento. Este paso servirá para eliminar el ruido y artefactos no deseados en las imágenes dermatoscópicas que servirán como entrada para distintos métodos de clasificación,

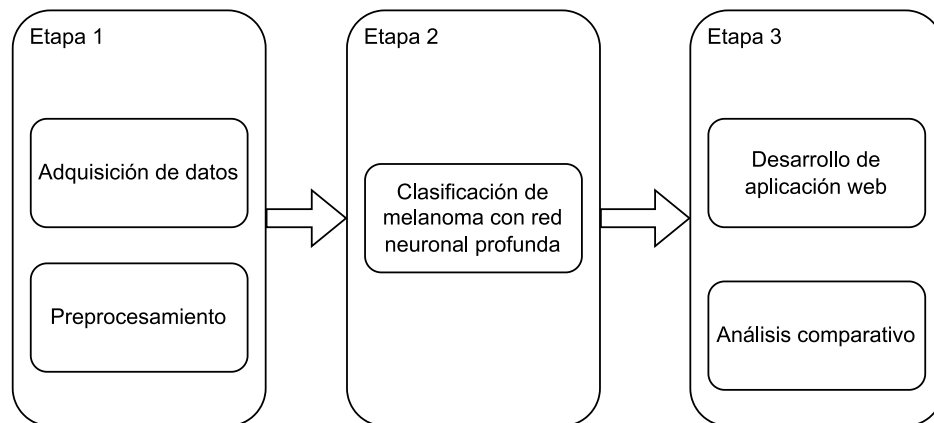


Figura 1.1: Metodología

- Etapa 2. En esta etapa se realiza la implementación y el entrenamiento del algoritmo de reconocimiento de melanoma.
  1. Clasificación de melanoma con red neuronal profunda. En este paso se realiza el entrenamiento de una red neuronal profunda para realizar la clasificación de melanoma, utilizando las características extraídas de forma automática por la misma red.
- Etapa 3. En esta etapa se desarrolla una aplicación web en idioma español usando el lenguaje de programación python para integrar y mostrar el uso práctico de los algoritmos implementados para reconocimiento de melanoma. Además, se realiza la evaluación y el análisis de resultados obtenidos.
  1. Desarrollo de aplicación web. Se realizará una aplicación web en idioma español que integre los algoritmos implementados para el reconocimiento de melanoma.
  2. Análisis comparativo. Se llevará a cabo un análisis comparativo del rendimiento del clasificador, entre dos arquitecturas de aprendizaje profundo implementadas.

## 1.8. Índice preliminar

1. Introducción
  - 1.1 Planteamiento del problema
  - 1.2 Justificación
  - 1.3 Hipótesis


- 1.4 Objetivos
  - 1.4.1 Objetivo general
  - 1.4.2 Objetivos específicos
- 1.5 Metas
- 1.6 Trabajos relacionados
- 1.7 Metodología
- 1.8 Cronograma de actividades
- 2. Marco teórico
  - 2.1 Detección del Cáncer de melanoma mediante imágenes dermatoscópicas
  - 2.2 Métodos de preprocesamiento de imágenes
  - 2.3 Aprendizaje profundo
- 3. Desarrollo del proyecto
- 4. Resultados
- 5. Conclusiones y trabajo futuro
- 6. Referencias

## 1.9. Cronograma de actividades

A continuación se describen las actividades a realizar para el desarrollo de este proyecto de tesis, las cuales se resumen en el Cuadro 1.1.

- **Actividad 1:** Revisar el estado del arte sobre los algoritmos utilizados como métodos de preprocesamiento en imágenes dermatoscópicas.
- **Actividad 2:** Revisar el estado del arte sobre los algoritmos basados en aprendizaje profundo, utilizados en la clasificación de melanoma.
- **Actividad 3:** Implementar técnicas de preprocesamiento del conjunto de imágenes seleccionadas.
- **Actividad 4:** Implementar dos algoritmos basados en redes neuronales profundas para clasificación de melanoma, en el lenguaje de programación Python.
- **Actividad 5:** Comparar el rendimiento de clasificación de los algoritmos basados en aprendizaje profundo.

- **Actividad 6:** Integrar los módulos implementados para la creación de una aplicación en python que sea capaz de reconocer melanoma en imagenes dermatoscópicas.
- **Actividad 7:** Redacción del documento de tesis.
- **Actividad 8:** Revisión de la tesis por el asesor.



Cuadro 1.1: Cronograma de actividades

# Capítulo 2

## Marco Teórico

En este capítulo se presenta una breve descripción de los temas principales que sustentan este proyecto de tesis. En la primera sección se explica lo relacionado con la enfermedad de melanoma, así como el uso de imágenes dermatoscópicas para su reconocimiento. En la segunda sección se presenta una breve introducción al preprocesamiento de imágenes dermatoscópicas. Por último, en la tercera sección se realiza una introducción a los métodos de aprendizaje profundo y su uso en la clasificación de melanoma.

### 2.1. Detección del Cáncer de melanoma mediante imágenes dermatoscópicas

En esta sección se muestra una breve explicación sobre el melanoma, así como la situación actual de esta enfermedad, tanto a nivel nacional como a nivel internacional. Se presenta además una descripción de las imágenes dermatoscópicas, sus características principales y los hallazgos en etapas relacionados con la enfermedad de melanoma

#### 2.1.1. Cáncer de Melanoma

El melanoma, el tipo más grave de cáncer de piel, se forma en las células (melanocitos) que producen melanina, el pigmento que le da color a la piel. El melanoma también puede manifestarse en los ojos y, rara vez, dentro del cuerpo, como en la nariz o la garganta (MayoClinic, 2022).

La proyección para los próximos años de la estadística de manifestación de melanoma es alarmante, ya que de acuerdo con las estadísticas presentadas por la Agencia Internacional para la Investigación del Cáncer (IARC, por sus siglas en inglés) en 2020, se diagnosticaron aproximadamente 325 000 nuevos casos de melanoma en todo el mundo y alrededor de 57

000 personas murieron a causa de la enfermedad.

La causa exacta de todos los melanomas no está clara, pero la exposición a la radiación ultravioleta (UV) de la luz solar o de las lámparas y de las camas solares aumenta el riesgo de tener melanoma. Limitar la exposición a la radiación UV puede ayudar a reducir el riesgo de tener melanoma(MayoClinic, 2022).

De acuerdo a (ASCO, 2019) los 4 tipos de melanomas de la piel, o cutáneos, más frecuentes son:

- Melanoma de extensión superficial. Este es el tipo más frecuente y representa el 70 % de los melanomas en Europa. Se origina normalmente en un lunar existente.
- Melanoma lentigo maligno. Este tipo de melanoma tiende a ocurrir en personas mayores. Normalmente, comienza en la cara, los oídos y los brazos, es decir, en la piel que a menudo está expuesta al sol.
- Melanoma nodular. Este tipo representa aproximadamente el 15 % de los melanomas. A menudo aparece rápidamente como un bulto en la piel. Por lo general es negro, pero puede ser rosa o rojo.
- Melanoma lentiginoso acral. Este tipo de melanoma se desarrolla en las palmas de las manos, las plantas de los pies, o debajo del lecho ungueal. En ocasiones aparece en personas con piel más oscura. El melanoma lentiginoso acral no está relacionado con la exposición al sol.

### 2.1.2. Uso de imágenes dermatoscópicas

Los primeros trabajos relacionados con el reconocimiento de melanoma en imágenes utilizan la técnica llamada dermatoscopia, la cual requiere de un dermatoscópio para visualizar con mayor nivel de detalle las lesiones. Esta técnica aplica diversas reglas dermatoscópicas con el objetivo de eliminar la subjetividad y la variabilidad del diagnóstico, así como mejorar el rendimiento del diagnóstico.

El procedimiento diagnóstico en dermatoscopia que ha sido aceptado por la mayoría de grupos de trabajo alrededor del mundo es el método de las dos etapas. En la primera etapa de este método, el objetivo es discernir si se trata de una lesión melanocítica o no melanocítica a través del reconocimiento de diversas características de las lesiones melanocíticas (retículo pigmentado, agregados de glóbulos, ramificaciones lineales, pigmentación azul-homogénea). En la segunda etapa se debe distinguir la naturaleza benigna o maligna de la lesión, esto mediante el uso de un método cualitativo como el análisis de patrones, o mediante métodos



semicuantitativos como la regla ABCD, el método de Menzies o la lista de los 7 puntos de Argenziano (Zaballos et al., 2004).

El método ABCD de Solz fue el primer método de análisis de patrones para el diagnóstico de melanoma, descrito por Stolz en 1994, con el objetivo de facilitar el diagnóstico a observadores menos experimentados. Se ha reportado que este método tiene una sensibilidad y especificidad del 90 % al 100 % (Tsao et al., 2004).

Los criterios que busca valorar el método ABCD se describen a continuación:

- **Asimetría:** se divide la lesión en dos ejes perpendiculares y se valora la simetría respecto del color, la forma y/o estructuras en ambos lados de los ejes. Se otorga una puntuación de cero si no existe asimetría en ningún eje; una puntuación de 1 si existe asimetría en un eje y una puntuación de 2 si se encuentra asimetría con respecto de los dos ejes. De manera que una lesión puede tener una puntuación de asimetría de 0 a 2 puntos.
- **Bordes:** la lesión se divide en 8 segmentos, cada segmento que presente una finalización abrupta del borde obtiene una puntuación de 1, de manera que la lesión puede tener una puntuación de 0 a 8 en bordes.
- **Color:** Se valora la presencia de seis colores: blanco, marrón claro, marrón oscuro, gris-azul, rojo y negro, otorgando 1 punto por cada color que se manifieste. El blanco solo puntúa cuando es más claro que la piel adyacente. Al menos uno de estos colores debe estar presente. Por lo que la lesión puede tener una puntuación de 1 a 6 en color.
- **Estructuras dermatoscópicas:** se consideran cinco estructuras, cada una que esté presente otorga una puntuación de 1. Debe observarse al menos una de ellas. Por lo que puede tener una puntuación de 1 a 5:

De acuerdo a (Zaballos et al., 2004) el “análisis de patrones” es el método con el que se obtienen mejores resultados pues permite un abordaje más completo de las lesiones pigmentadas y es el que requiere mayor experiencia. En las lesiones melanocíticas permite el reconocimiento entre las lesiones benignas y malignas. Los patrones que sugieren malignidad son este método son:

- **Retículo pigmentado prominente o atípico.** El retículo pigmentado es una red de líneas de color marrón o negro sobre fondo marrón más claro. El retículo pigmentado típico es aquel con una red homogénea con líneas finas y orificios pequeños. El retículo prominente es aquel con una red homogénea pero compuesta por líneas gruesas y más oscuras; mientras que el atípico es heterogéneo e irregular con orificios de distintos tamaños. El retículo pigmentado atípico mostró una asociación mayor con el diagnóstico

de melanoma. El retículo pigmentado negativo es una estructura formada por una red con líneas ligeramente pigmentadas y orificios oscuros dando una imagen “en negativo” del retículo. Es una estructura que se presenta en melanoma y nevo de Spitz.

- Puntos y glóbulos irregulares. Estructuras circulares pigmentadas menores de 0.1mm (puntos) o mayores de 0.1mm (glóbulos) y de color negro (si están localizados en capa córnea), marrones (en epidermis) o azules (en dermis). La presencia de puntos y glóbulos de diferentes tamaños y coloración distribuidos de forma irregular en la lesión melanocítica puede sugerir malignidad.
- Proyecciones irregulares. Corresponden a estructuras lineales radiadas en la periferia de la lesión que se extienden en la piel normal adyacente. Existen dos tipos: los pseudópodos y las proyecciones radiales; las primeras tienen una apariencia bulbosa, digitiforme, mientras que las segundas son estructuras lineales radiadas y finas. La importancia radica en su distribución en la lesión melanocítica; si se distribuyen de forma irregular y asimétrica son altamente sugestivos de la fase de extensión superficial del melanoma.
- Velo azul-gris o azul-blانquecino. Pigmentación difusa confluyente azul-grisácea o azul blanquecina, con ausencia de estructuras en su interior, que no debe ocupar la lesión por completo. Suele estar recubierta por un velo blanquecino que le otorga una apariencia en vidrio esmerilado. Es uno de los parámetros más específicos de melanoma.
- Áreas desestructuradas. Corresponden a zonas, dentro de la lesión melanocítica en la que no pueden distinguirse estructuras en su interior. Pueden ser hiperpigmentadas de color marrón, gris o negro (manchas de pigmento) o bien áreas de hipopigmentación. Cuando se distribuyen de forma irregular y focal son más características de lesión maligna.
- Estructuras de regresión. Pueden distinguirse áreas de regresión azul, blanca y mixta. Las áreas de regresión azul denominadas “áreas con punteado azul” o “en pimienta” porque se aprecian como áreas de color azul-grisáceo con un punteado fino en su interior. Las áreas de regresión blancas o llamadas pseudocicatriciales pues recuerdan una cicatriz superficial. Las áreas de regresión mixtas contienen ambos tipos. Las estructuras de regresión se asocian con frecuencia a melanoma.
- Estructuras vasculares asociadas a malignidad. En los casos de melanomas amelanicos pueden ser la única clave diagnóstica. Existen cinco estructuras vasculares asociadas a melanoma:
  - Vasos puntiformes o “en cabeza de alfiler” que corresponden a vasos con aspecto de asa que penetran en el tumor desde los plexos dérmicos.
  - Vasos en horquilla similares a los anteriores pero presentan un mayor grosor vertical.

- Vasos lineales con morfología y distribución irregular. o Glóbulos rojo-azulados
- Rojo-lechosos, que corresponden a nódulos bien vascularizados del melanoma.
- Vasos y/o eritema en el interior de estructuras de regresión.

## 2.2. Preprocesamiento general de imágenes

La presencia de elementos indeseados o ruido relacionados con el método utilizado para la adquisición de las imágenes es un problema común que afecta la calidad de las imágenes, y que por consecuencia también afecta el rendimiento de los métodos de segmentación y clasificación. (Pal y Sudeep, 2016). El preprocesamiento permite resaltar las características de la imagen o eliminar ruido o artefactos no deseados.

Los métodos de preprocesamiento de imágenes más recomendados dependen de cada aplicación. Se pueden clasificar en transformaciones en el dominio espacial o de las frecuencias. Las transformaciones en el dominio espacial permiten modificar directamente los valores de intensidad que componen la imagen. Las transformaciones en el dominio frecuencial requieren previamente convertir la representación de la imagen, al dominio de las frecuencias mediante la transformada de Fourier, y en este dominio aplicar diversos filtros. (Nixon-Mark y Aguado-Alberto, 2019)

También estos métodos de preprocesamiento suelen clasificarse en tres tipos: los métodos basados en operaciones puntuales, locales y globales (Morales-Roberto y Azuela-Juan, 2012). Los métodos basados en operaciones puntuales modifican el valor de intensidad de un píxel a la vez utilizando expresiones matemáticas simples. Mientras que los métodos basados en operaciones locales utilizan una matriz de píxeles llamada vecindad para delimitar los píxeles adyacentes al píxel de entrada. Estos filtros pueden dividirse en lineales y no lineales, los primeros se basan en operaciones de convolución, mientras que los segundos se basan en operaciones estadísticas sobre los valores de intensidad que componen la vecindad. Por últimos, los métodos de preprocesamiento basados en operaciones globales modifican los valores de intensidad de todos los píxeles que componen la imagen a la vez.

### 2.2.1. Métodos de preprocesamiento en imágenes dermatoscópicas

Las imágenes dermatoscópicas suelen contener ruido o artefactos y relacionados con la lesión de interés que pueden afectar el rendimiento de la etapa de segmentación y, por consiguiente, también el rendimiento de la etapa de clasificación. Los artefactos que suelen aparecer en las imágenes de dermatoscopia pueden ser de dos tipos diferentes: i) artefactos de adquisición (burbujas de aire, reflejos, marcas de regla y tinta, y marcos negros); y ii)

artefactos cutáneos (líneas de la piel, vasos sanguíneos y pelos) (Celebi et al., 2015). Estos artefactos dificultan el proceso de segmentación de la lesión, lo que a su vez da lugar a características de forma y simetría engañosas, también añaden información de color y textura que puede generar una interpretación errónea de las características de la lesión.

La estrategia más sencilla para tratar estos artefactos es aplicar un operador de suavizado (por ejemplo, un filtro de mediana o de media) a la imagen dermatoscópica (Fleming et al., 1998). Estos operadores ayudan a eliminar algunos artefactos como líneas de la piel, vasos sanguíneos y pelos finos. Estos enfoques funcionan bastante bien para algunos artefactos (líneas de la piel, vasos sanguíneos y pelos finos). Sin embargo, deben aplicarse cuidadosamente, ya que el uso de grandes máscaras de filtro puede provocar el desenfoque de la imagen y la consiguiente pérdida de propiedades de textura y definición de los bordes.

Durante el preprocesamiento también es posible enfatizar los parámetros de iluminación y contraste en las imágenes (Gazioglu y Kamaşak, 2021; Vocaturo et al., 2018), esto con el fin de reducir la variabilidad en las propiedades de color resultante de las diferentes condiciones de iluminación y tipo de cámaras digitales en las imágenes dermatoscópicas. Con frecuencia, esta variabilidad en las propiedades de color reduce la fiabilidad del uso de la información de color para diagnosticar las lesiones. Para solucionar este problema se aplican técnicas de normalización de color las cuales pueden estar basadas en hardware o en software (Celebi et al., 2015). Las primeras requieren conocer las propiedades específicas del dispositivo de adquisición (por ejemplo, el desplazamiento de la cámara, la ganancia de color y la apertura) para estimar una matriz de transformación que pueda utilizarse para convertir las imágenes a un espacio de color independiente del dispositivo (Grana et al., 2005; Wighton et al., 2011; Quintana et al., 2011). A veces no es posible acceder a la información mencionada, lo que limita la aplicación de los métodos basados en hardware. Por otro lado, los métodos basados en software no requieren un conocimiento previo de la configuración de la adquisición y utilizan las propiedades de la imagen para realizar la normalización (Barata, Celebi, y Marques, 2014).

La mejora del contraste es una técnica que tiene como objetivo aumentar el contraste entre el borde de la lesión y la piel circundante (Schaefer, Rajab, Celebi, y Iyatomi, 2011). Por otro lado, de acuerdo a (Celebi, Codella, y Halpern, 2019) el espacio de color por defecto de las imágenes de dermatoscopia es el RGB (rojo-verde-azul). Este espacio de color presenta varios inconvenientes: i) no es perceptivamente uniforme; ii) no es independiente del dispositivo; iii) existe una alta correlación entre los canales. Esto ha motivado el uso de espacios de color alternativos, como CIE  $L^*a^*b^*$ , CIE  $L^*u^*v$ , HSV, y el oponente, para extraer información de color relevante (Pathan et al., 2018). Además del procesamiento multicanal, también es habitual convertir la imagen de dermatoscopia RGB a un solo canal para realizar la segmentación de la lesión o para extraer características de textura (Celebi et al., 2015).

Por último, la eliminación del pelo es un tema de investigación popular (Lee et al., 1997; Abbas et al., 2011), que comprenden dos pasos principales: la identificación y la reparación del pelo. Esta última suele realizarse mediante un algoritmo de restauración de imagen para reemplazar el espacio ocupado por el pelo con valores de intensidad o color adecuados. Aunque la eliminación del pelo ha demostrado ser muy útil, es necesario prestar especial atención al resultado de los algoritmos, ya que pueden introducir algún anillo borroso o deformación de la textura en las zonas cubiertas con muchos pelos. Además, los algoritmos pueden tratar las estructuras dermatoscópicas oscuras y lineales (por ejemplo, la red de pigmentos) como pelos, y eliminarlas (Celebi et al., 2019).

## 2.3. Aprendizaje profundo

El aprendizaje profundo es una clase de técnicas de aprendizaje automático, en las que la información se procesa en capas jerárquicas para considerar representaciones y características de los datos en niveles de complejidad crecientes.

### 2.3.1. Introducción

De acuerdo a (Vasilev et al., 2019), Una neurona es una función que toma uno o más valores de entrada y emite un único valor numérico, se define de la siguiente manera

$$y = f\left(\sum_i x_i w_i + b\right) \quad (2.1)$$

donde,

- $x_i$  son valores numéricos que representan los datos de entrada o las salidas de otras neuronas.
- $w_i$  son pesos que representan la fuerza de las entras.
- $b$  es un peso llamado sesgo, cuyo valor es siempre 1.
- $f$  es la función de activación o transferencia.

Dos características principales de una red neuronal son:

- **La arquitectura de la red neuronal.** Describe el conjunto de conexiones entre las neuronas, por ejemplo, si es una red con conexiones hacia delante, recurrente, multipa o monopa. Además, también describe el número de capas y el número de neuronas

en cada capa.

- **El aprendizaje.** Describe lo que comúnmente se define como el entrenamiento. La forma más común, aunque no exclusiva, de entrenar una red neuronal es con el algoritmo del descenso del gradiente y la retropropagación.

### 2.3.2. Redes neuronales profundas

Las redes neuronales de una capa solo pueden clasificar clases linealmente separables, para superar esta limitación se vuelve necesario introducir más capas entre la entrada y la salida. Estas capas intermedias se denominan capas ocultas y dan origen a las redes profundas. Una red profunda descubre características automáticamente durante el entrenamiento. Estas características podrían no ser inmediatamente obvias y, en general, no serían interpretables por los humanos. Este proceso se denomina ingeniería de características, y puede requerir mucho trabajo y tiempo.

Existen diversos tipos de redes neuronales profundas las cuales se diferencian por la forma en que las neuronas se organizan en las diferentes capas de las redes. La siguiente lista muestra las principales clases de redes neuronales que se utilizan actualmente.

- **Redes neuronales convolucionales (CNN):** Una CNN es una red neuronal de avance con varios tipos de capas especiales. Por ejemplo, las capas convolucionales aplican un filtro a la imagen (o sonido) de entrada deslizando ese filtro por toda la señal entrante, para producir un mapa de activación de  $n$  dimensiones. Existen pruebas de que las neuronas de las CNN se organizan de forma similar a como se organizan las células biológicas en la corteza visual del cerebro.
- **Redes recurrentes:** Este tipo de red tiene un estado interno (o memoria), que se basa en la totalidad o parte de los datos de entrada ya alimentados a la red. La salida de una red recurrente es una combinación de su estado interno (memoria de entradas) y entrada. Al mismo tiempo, el estado interno cambia para incorporar los nuevos datos de entrada. Debido a estas propiedades, las redes recurrentes son buenas candidatas para las tareas que trabajan con datos secuenciales, como el texto o los datos de series temporales.
- **Autocodificadores:** Es un tipo de red que utiliza aprendizaje no supervisado, en los que la forma de salida es la misma que la de entrada, lo que permite a la red aprender mejor las representaciones básicas. Los codificadores automáticos también son modelos generativos que pueden generar aleatoriamente nuevos datos que son similares a los datos de entrada (datos de entrenamiento).

## Bibliografía

- Abbas, Q., Celebi, M. E., y García, I. F. (2011). Hair removal methods: A comparative study for dermoscopy images. *Biomedical Signal Processing and Control*, 6(4), 395–404.
- ACS. (2022a). *American cancer society: Pruebas para el cáncer de piel tipo melanoma*. Recuperado Agosto de 2022, de: <https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/deteccion-diagnostico-clasificacion-por-etapas/como-se-diagnostica.html>.
- ACS. (2022b). *American cancer society: ¿qué es el cáncer de piel tipo melanoma?*. Recuperado Agosto de 2022, de: <https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/acerca/que-es-melanoma.html>.
- Amin, J., Sharif, A., Gul, N., Anjum, M. A., Nisar, M. W., Azam, F., y Bukhari, S. A. C. (2020). Integrated design of deep features fusion for localization and classification of skin cancer. *Pattern Recognition Letters*, 131(6), 63-70.
- Anjum, M. A., Amin, J., Sharif, M., Khan, H. U., Malik, M. S. A., y Kadry, S. (2020). Deep semantic segmentation and multi-class skin lesion classification based on convolutional neural network. *IEEE Access*, 8, 129668–129678.
- ASCO. (2019). *Sociedad americana de oncología clínica melanoma: Diagnóstico*. Recuperado Enero de 2022, de: <https://www.cancer.net/es/tipos-de-cancer/melanoma/diagnostico>.
- Barata, C., Celebi, M. E., y Marques, J. S. (2014). Improving dermoscopy image classification using color constancy. *IEEE journal of biomedical and health informatics*, 19(3), 1146–1152.
- Celebi, M. E., Codella, N., y Halpern, A. (2019). Dermoscopy image analysis: overview and future directions. *IEEE journal of biomedical and health informatics*, 23(2), 474–478.
- Celebi, M. E., Wen, Q. U. A. N., Iyatomi, H. I. T. O. S. H. I., Shimizu, K. O. U. H. E. I., Zhou, H., y Schaefer, G. (2015). A state-of-the-art survey on lesion border detection in dermoscopy images. *Dermoscopy image analysis*, 10, 97–129.
- Conforti, C., Giuffrida, R., Retrosi, C., di Meo, N., y Zalaudek, I. (2019). Two controversies confronting dermoscopy or dermatoscopy: nomenclature and results. *Clinics in Dermatology*, 37(5), 597–599.
- Fleming, M. G., Steger, C., Zhang, J., Gao, J., Cognetta, A. B., y Dyer, C. R. (1998). Techniques for a structural analysis of dermatoscopic imagery. *Computerized medical imaging and graphics*, 22(5), 375–389.
- Gazioğlu, B. S. A., y Kamaşak, M. E. (2021). Effects of objects and image quality on melanoma classification using deep neural networks. *Biomedical Signal Processing and Control*, 67, 102530.
- Gong, A., Yao, X., y Lin, W. (2020). Dermoscopy image classification based on stylegans and decision fusion. *Ieee Access*, 8, 70640–70650.
- Goyal, M., Knackstedt, T., Yan, S., y Hassanpour, S. (2020). Artificial intelligence-based image classification methods for diagnosis of skin cancer: Challenges and opportunities.

- Computers in Biology and Medicine*, 127, 104065.
- Grana, C., Pellacani, G., y Seidenari, S. (2005). Practical color calibration for dermoscopy, applied to a digital epiluminescence microscope. , 11(4), 242–247.
- Hernández-Domínguez, D. A., Aldaco-Sarvide, F., Cervantes-Sánchez, G., Erazo-Valle-Solís, A. A., Pérez-Pérez, P., Torrecillas-Torres, L., y Alvarado, G. D. (2019). La mortalidad por melanoma en México aumenta. *Revista de Especialidades Médico-Quirúrgicas*, 23(3), 123–129.
- Hosny, K. M., Kassem, M. A., y Foad, M. M. (2020). Skin melanoma classification using roi and data augmentation with deep convolutional neural networks. *Multimedia Tools and Applications*, 79(33), 24029–24055.
- Kasmi, R., y Mokrani, K. (2016). Classification of malignant melanoma and benign skin lesions: implementation of automatic ABCD rule. *IET Image Processing*, 10(6), 448–455.
- Khan, M. Q., Hussain, A., Rehman, S. U., Khan, U., Maqsood, M., Mehmood, K., y Khan, M. A. (2019). Classification of melanoma and nevus in digital images for diagnosis of skin cancer. *IEEE Access*, 7, 90132–90144.
- Lee, T., Ng, V., Gallagher, R., Coldman, A., y McLean, D. (1997). Dullrazor®: A software approach to hair removal from images. *Computers in biology and medicine*, 27(6), 533–543.
- López-Salmerón, N. (2021). Proyecto de fin de carrera. Escuela técnica superior de ingeniería y sistemas de telecomunicación. Sistema automatizado de detección y clasificación mediante Deep Learning de atributos dermatoscópicos en lesiones de la piel para diagnóstico de melanoma.
- Majumder, S., y Ullah, M. A. (2019). Feature extraction from dermoscopy images for melanoma diagnosis. *SN Applied Sciences*, 1(7), 1–11.
- MayoClinic. (2022). *Enfermedades y afecciones: Melanoma*. Recuperado Noviembre de 2022, de: <https://www.mayoclinic.org/es-es/diseases-conditions/melanoma/symptoms-causes/syc-20374884>.
- Mazouze, B., Mazouze, A., Bédard, J., y Makarenkov, V. (2022). Dunescan: a web server for uncertainty estimation in skin cancer detection with deep neural networks. *Scientific Reports*, 12(1), 1–10.
- Melbin, K., y Raj, Y. (2021). Integration of modified ABCD features and support vector machine for skin lesion types classification. *Multimedia Tools and Applications*, 80(6), 8909–8929.
- Morales-Roberto, y Azuela-Juan. (2012). *Procesamiento y análisis digital de imágenes*. Alfaomega.
- Naeem, A., Farooq, M. S., Khelifi, A., y Abid, A. (2020). Malignant melanoma classification using deep learning: datasets, performance measurements, challenges and opportunities. *IEEE Access*, 8, 110575–110597.
- Nixon-Mark, y Aguado-Alberto. (2019). *Feature extraction and image processing for com-*



- puter vision*. Academic press.
- Pal, K. K., y Sudeep, K. S. (2016). Preprocessing for image classification by convolutional neural networks. En *2016 iee international conference on recent trends in electronics, information & communication technology (rteict)* (pp. 1778–1781).
- Palacios-Martínez, D., y Díaz-Alonso, R. A. (2017). Dermatoscopia para principiantes (i): características generales. *Medicina de Familia*, 43, 216–221.
- Pathan, S., Prabhu, K. G., y Siddalingaswamy, P. C. (2018). Techniques and algorithms for computer aided diagnosis of pigmented skin lesions—a review. *Biomedical Signal Processing and Control*, 39, 237–262.
- POCV. (2010). *Plan oncológico comunidad valenciana pocv, guía de prevención y tratamiento del melanoma 2010*. Recuperado Octubre de 2022, de: <https://www.ivo.es/wp-content/uploads/2015/03/GUIA-DE-PREVENCIÓN-Y-TRATAMIENTO-DEL-MELANOMA-CONSELLERIA-DE-SANITAT.pdf>.
- Quero-Caiza, W., y Altuve, M. (2022). Recognition of skin lesions in dermoscopic images using local binary patterns and multinomial logistic regression. *IEEE Latin America Transactions*, 100(XXX).
- Quintana, J., Garcia, R., y Neumann, L. (2011). A novel method for color correction in epiluminescence microscopy. *Computerized Medical Imaging and Graphics*, 35(7-8), 646–652.
- Sarkar, R., Chatterjee, C. C., y Hazra, A. (2019). Diagnosis of melanoma from dermoscopic images using a deep depthwise separable residual convolutional network. *IET Image Processing*, 13(12), 2130–2142.
- Schaefer, G., Rajab, M. I., Celebi, M. E., y Iyatomi, H. (2011). Colour and contrast enhancement for improved skin lesion segmentation. *Computerized Medical Imaging and Graphics*, 35(2), 99–104.
- Sultana, N. N., Mandal, B., y Puhan, N. B. (2018). Deep residual network with regularised fisher framework for detection of melanoma. *IET Computer Vision*, 12(8), 1096–1104.
- Tsao, H., Atkins, M. B., y Sober, A. J. (2004). Management of cutaneous melanoma. *New England Journal of Medicine*, 351(10), 998–1012.
- Vasilev, I., Slater, D., Spacagna, G., Roelants, P., y Zocca, V. (2019). *Python deep learning: Exploring deep learning techniques and neural network architectures with pytorch, keras, and tensorflow*. Packt Publishing Ltd.
- Vocaturro, E., Zumpano, E., y Veltri, P. (2018). Image pre-processing in computer vision systems for melanoma detection. En *2018 iee international conference on bioinformatics and biomedicine (bibm)* (pp. 2117–2124).
- Wahba, A. A. G. Y. N. S. . E. M., M. (2018). A novel cumulative level difference mean based GLDM and modified ABCD features ranked using eigenvector centrality approach for four skin lesion types classification. *Computer methods and programs in biomedicine*, 165, 163–174.
- Wighton, P., Lee, T. K., Lui, H., McLean, D., y Atkins, M. S. (2011). Chromatic aberration

- correction: an enhancement to the calibration of low-cost digital dermoscopes. *Skin Research and Technology*, 17(3), 339–347.
- Xie, F., Fan, H., Li, Y., Jiang, Z., Meng, R., y Bovik, A. (2016). Melanoma classification on dermoscopy images using a neural network ensemble model. *IEEE transactions on medical imaging*, 36(3), 849–858.
- Yuan, Y., Chao, M., y Lo, Y. C. (2017). Automatic skin lesion segmentation using deep fully convolutional networks with jaccard distance. *IEEE transactions on medical imaging*, 36(9), 1876–1886.
- Zaballos, P., Carrera, C., Puig, S., y Malvehy, J. (2004). Criterios dermatoscópicos para el diagnóstico del melanoma. *Medicina cutánea ibero-latino-americana*, 32(1), 3–17.